

기초통계 과제: Dailybox 마케팅 전략 분석 (템플릿)

응용통계학과 2024122026 윤소현

Part 1. 고객의 이해 (EDA)

1. 데이터 로드 및 구조 확인

Q: 고객 규모와 주요 수치 변수 범위를 한두 줄로 요약하세요.

총 6,000명의 고객 데이터로 결측치는 없으며, 나이는 18세~최고 연령, 월 방문 횟수는 1~회, 월 구매액(monthly_spend)은 넓은 범위를 가집니다. 수치형 변수 전반에서 소수의 고가치 고객 중심으로 분포가 넓게 퍼져 있는 특징을 보입니다.

2. 매출 분포와 로그변환

Q: 매출 분포가 왜 치우쳐 있는지, 로그변환이 왜 도움이 되는지 서술하세요.

매출 분포 왜곡 원인: monthly_spend의 분포는 오른쪽으로 긴 꼬리를 가진 형태(양의 왜도)를 보입니다. 이는 대다수의 일반 고객이 평균적인 수준의 금액을 소비하는 반면, 소수의 고가치 고객이 매우 큰 금액을 소비하여 매출이 한쪽으로 쏠려 있기 때문입니다.

로그변환(log1p)의 효과: 오른쪽으로 치우친 왜곡된 분포를 대칭적인 정규분포 형태로 완만하게 만들어 줍니다. 이를 통해 이상치의 영향력을 줄이고, 향후 회귀분석이나 통계적 검정 시 요구되는 정규성 가정을 충족시키는 데 큰 도움을 줍니다.

3. 채널·등급별 매출 Boxplot

Q: 어떤 채널/등급이 고가치 고객으로 보이는지 해석하세요.

유입 채널별 해석: Influencer와 Referral 채널을 통해 유입된 고객들의 월 구매액(monthly_spend) 중위수와 전체적인 분포가 Organic Search나 Social Ads에 비해 높게 형성되어 있습니다. 특히 Influencer 채널은 상위 고가치 고객층(이상치 구간)이 두텁게 분포하여 가장 충성도 높은 고가치 고객을 데려오는 채널로 해석됩니다.

멤버십 등급별 해석: 예상대로 Gold 등급으로 갈수록 월 구매액의 중위수와 사분위수 범위가 상향되어 있으며, 등급이 높을수록 고가치 고객의 비중이 뚜렷하게 증가하는 경향을 보입니다.

Part 2. 가정 확인

4. 1종/2종 오류 (개념)

Q: "쿠폰 캠페인은 효과가 없다"는 H_0 에 대해 1종 오류와 2종 오류가 각각 무엇을 의미하고, 어떤 손실을 끼치는지 서술하세요.

- 1종 오류 (Type I Error)의미: 실제로는 쿠폰 캠페인이 매출에 아무런 효과가 없는 데(귀무가설 참), 효과가 있다고 잘못 판단하여 채택하는 오류입니다. 이는 효과가 없는 마케팅 캠페인임에도 지속하거나 예산을 투입하게 되어 마케팅 예산 낭비라는 직접적인 재정적 손실을 초래합니다.
- 2종 오류 (Type II Error)의미: 실제로는 쿠폰 캠페인이 매출 증대에 효과가 있는데(귀무가설 거짓), 효과가 없다고 잘못 판단하여 기각하지 못하는 오류입니다. 이는 실제로 매출을 견인할 수 있는 우수한 캠페인임에도 이를 중단하거나 폐기하게 되어, 잠재적인 매출 성장의 기회를 날리게 되는 기회 손실을 입게 됩니다.

5. 정규성 검정 (Shapiro-Wilk) – 원본 vs 로그

Q: 가설을 세우고, 두 결과를 0.05 기준으로 비교 해석하세요.

가설

- 설정귀무가설 (H_0): 해당 데이터(monthly_spend)는 정규분포를 따른다.
- 대립가설 (H_1): 해당 데이터(monthly_spend)는 정규분포를 따르지 않는다.

결과 해석 및 비교 (유의수준 0.05 기준)

- 원본 데이터 (좌측 Q-Q Plot): 데이터가 빨간색 기준선을 크게 벗어나 S자 형태로 휘어져 있습니다. Shapiro-Wilk 검정 결과 p-value가 0.05보다 훨씬 작게 나타나므로 귀무가설을 기각하며, 원본 데이터는 정규성을 만족하지 않습니다.
- 로그변환 데이터 (우측 Q-Q Plot): $\log_{10}$ 변환을 거친 후에는 점들이 빨간색 직선 주변에 훨씬 나란하게 밀집되어 정규분포 패턴에 근접하는 것을 확인할 수 있습니다. 이처럼 로그변환이 데이터의 정규성 충족에 효과적임을 확인할 수 있습니다.

6. 등분산성 검정

Q: p값을 0.05 기준으로 해석하고, ANOVA에 어떤 의미인지 서술하세요.

Levene 검정 p-value 해석 (유의수준 0.05 기준)

검정 결과 p-value가 0.05보다 훨씬 작으므로($p < 0.05$), 귀무가설(4개 유입 채널 간 분산이 동일하다)을 기각합니다. 즉, 유입 채널 간 분산이 동일하지 않다(등분산성이 깨져 있다)는 결론을 내립니다.

ANOVA(분산분석)에 미치는 의미

전통적인 One-way ANOVA는 기본적으로 등분산성 가정을 전제로 합니다. 본 데이터에서 등분산성이 기각되었으므로, 채널 간 평균 비교를 진행할 때 일반적인 ANOVA 결과가 왜곡될 가능성이 있음을 인지해야 합니다. 따라서 향후 분산분석 결과를 해석하거나 사후검정(Tukey HSD 등) 및 후속 분석을 수행할 때 이 점을 유의하거나 이분산성을 보완하는 대안적 방법(예: Welch's ANOVA 등)을 함께 고려해야 함을 시사합니다.

Part 3. 집단 비교 검정

7. 쿠폰 캠페인 효과 검증 – 두 집단 평균 비교 (Welch's t-test)

Q: H_0 / H_1 을 명시하고, 캠페인을 지속할지 결론 내리세요.

가설 설정

- 귀무가설 (H_0): 쿠폰 캠페인 발송 집단과 미발송 집단 간의 월 구매액 (monthly_spend) 평균에 차이가 없다.
- 대립가설 (H_1): 쿠폰 캠페인 발송 집단과 미발송 집단 간의 월 구매액 (monthly_spend) 평균에 차이가 있다.

결과 해석 및 결론 (유의수준 0.05 기준)

- Levene 검정 결과 등분산성 가정이 기각되어 Welch's t-test를 수행한 결과, p-value가 $3.86e-32$ 로 0.05보다 훨씬 작습니다. 따라서 귀무가설을 기각하고 대립가설을 채택합니다.
- 캠페인 지속 여부: 쿠폰 캠페인 발송 집단(treatment)의 평균 매출이 미발송 집단(control)에 비해 통계적으로 유의하게 높으므로 다음 분기에도 쿠폰 캠페인을 계속 지속해야 한다는 결론을 내립니다.

8. 채널 비교 – One-way ANOVA + Tukey HSD

Q: 가설을 세우고, 어느 채널이 유의하게 고가치/저가치인지 결론지으세요.

가설 설정

- 귀무가설 (H_0): 4개의 유입 채널(signup_channel) 간 월 구매액(monthly_spend) 평균에 차이가 없다.
- 대립가설 (H_1): 4개의 유입 채널 간 월 구매액(monthly_spend) 평균에 차이가 있다.

결과 해석 및 채널별 평가 (유의수준 0.05 기준)

- One-way ANOVA 결과 p-value가 $2.67e-168$ 로 0.05보다 훨씬 작으므로 귀무가설을 기각합니다. 즉, 유입 채널에 따라 고객의 구매력에 유의한 차이가 존재합니다.
- Tukey HSD 사후검정 결과: 모든 채널 쌍 간의 비교에서 reject = True (p-adj = 0.0)로 나타나, 4개 채널 간의 평균 매출이 모두 통계적으로 유의한 차이를 보입니다.
- 고가치 / 저가치 채널 결론: Part 1의 Boxplot 시각화 결과와 사후검정의 평균 차이(meandiff)를 종합할 때, Influencer 채널이 가장 높은 매출을 기록하여 유의한 고가치 고객을 데려오는 채널로 평가됩니다. 그 뒤를 이어 Referral 채널이 높은 편이며, Organic Search와 Social Ads 채널은 상대적으로 낮은 매출을 보여 저가치 고객 세그먼트로 판단됩니다.

9. 교호작용 – Two-way ANOVA (선택 심화)

Q: 각 주효과와 교호작용의 유의성을 해석하세요.

주효과(Main Effects) 해석

- signup_channel 주효과: p-value가 $6.336934e-173$ 으로 유의수준 0.05 기준에서 매우 유의합니다. 이는 앞선 분석과 마찬가지로 유입 채널에 따라 고객의 월 구매액에 유의한 차이가 있음을 재확인해 줍니다.
- campaign_group 주효과: p-value가 $3.634363e-36$ 으로 매우 유의합니다. 쿠폰 캠페인 발송 여부가 고객의 매출에 통계적으로 유의미한 영향을 미친다는 것을 보여줍니다.

교호작용(Interaction) 해석 (signup_channel : campaign_group)

교호작용의 p-value가 3.973329e-06 으로 0.05보다 작아 통계적으로 유의합니다.

- ➔ 비즈니스적 해석: 캠페인의 효과가 유입 채널마다 다르다는 것을 의미합니다. 즉, 모든 채널에 일괄적으로 쿠폰을 뿌리는 것보다 특정 채널(예: 고가치 채널 또는 반응이 더 민감한 채널)에 따라 캠페인의 성과나 매출 증대 폭에 차이가 존재하므로, 채널별 특성을 고려한 차별화된 마케팅 전략 수립이 필요함을 시사합니다.

10. 단순선형회귀 & 다중회귀

Q: 방문·할인·광고비 중 매출에 실제로 기여하는 레버는? 할인 확대는 좋은 전략인가? 채널 계수는 어떻게 해석되나?

매출에 실제로 기여하는 레버 (방문·할인·광고비)

- 다중회귀 분석 결과, monthly_visits(월 방문 횟수, 계수 ≈ 0.9166), avg_discount_rate(평균 할인율, 계수 ≈ 11.4233), online_ad_cost(온라인 광고비, 계수 ≈ 0.3681) 모두 p-value가 0.000으로 매출(monthly_spend)에 통계적으로 유의한 양(+)의 영향을 미치는 것으로 나타났습니다.
- ➔ 따라서 방문 횟수 증대, 적절한 할인 정책, 온라인 광고비 집행 모두 매출을 끌어올리는 중요한 레버로 작용합니다.

할인 확대는 좋은 전략인가?

avg_discount_rate의 회귀계수가 양수(+)로 나타나지만, 마케팅/비즈니스 관점에서 무분별한 할인 확대는 매출 외형을 키울 수 있을지 몰라도 실제 마진과 순수익(Profit)을 악화시킬 위험이 있으므로 단순한 할인율 확대는 신중하게 접근해야 하는 전략입니다.

유입 채널 및 성별 계수 해석

- Influencer 채널을 기준(Reference)으로 할 때, 다른 채널들(Organic Search, Referral, Social Ads)의 계수가 모두 음수(-)로 나타났습니다. 이는 인플루언서 채널에 비해 다른 채널들의 평균 매출 수준이 통계적으로 유의하게 낮음을 의미합니다.
- 성별의 경우 C(gender)[T.Male] 계수가 음수(-)로 나타나, 여성 고객에 비해 남성 고객의 평균 월 구매액이 다소 낮거나 차이가 있음을 보여줍니다.

모형 설명력 비교 (R^2 & Adjusted R^2)

단순회귀 모형의 R^2 는 약 0.054에 불과했으나, 여러 설명변수와 더미변수가 추가된 다중

회귀 모형의 R^2 (및 수정된 결정계수 Adj. R^2)는 **약 0.218(21.8%)**로 대폭 향상되어 모형의 설명력이 개선되었음을 확인할 수 있습니다.

11. 다중 공선성 / VIF – online + offline + total 모두 넣기

Q: VIF에 어떤 문제가 있고 왜 그런지(total=online+offline), 어떻게 해결하는지 서술하세요.

VIF 결과 및 문제점

online_ad_cost, offline_ad_cost, total_ad_cost를 모두 포함하여 VIF를 계산한 첫 번째 결과에서, 세 변수의 VIF 값이 inf(무한대)로 치솟는 심각한 다중공선성 문제가 발생합니다.

원인 분석 (total = online + offline)

total_ad_cost는 정의상 online_ad_cost와 offline_ad_cost의 합(total_ad_cost = online_ad_cost + offline_ad_cost)으로 완벽하게 선형 종속되어 있는 변수입니다. 이처럼 독립변수 간에 완벽한 상관관계가 존재할 경우 회귀 모형의 계산이 불안정해지고 분산이 무한정 커지게 됩니다.

해결책 및 비교

완벽한 선형 종속을 유발하는 종속(합계) 변수인 total_ad_cost를 모형에서 제외합니다.

- ➔ 실제로 total_ad_cost를 제거하고 online_ad_cost와 offline_ad_cost만 남긴 두 번째 VIF 결과를 보면, 모든 변수의 VIF 값이 1에 가까운 안정적인 수치로 대폭 낮아져 다중공선성 문제가 깔끔하게 해결되는 것을 확인할 수 있습니다.

12. 잔차 진단 (+ 로그변환 비교)

Q: 원본 대비 로그변환 모형의 잔차가 어떻게 개선되는지 서술하세요.

잔차 정규성 개선 (Q-Q Plot 비교)

- 원본 모형: Q-Q Plot 에서 잔차가 양의 방향(우측 상단)으로 붉은색 기준선을 크게 벗어나 휘어지는 현상이 나타나며, 이는 잔차가 정규분포를 따르지 않고 왜곡되어 있음을 보여줍니다.
- 로그변환 모형 (log1p): 종속변수에 로그변환을 적용한 모형은 Q-Q Plot 의 데이터 포인트들이 대다수 붉은색 직선 주위에 나란하게 밀집되어, 잔차의 정규성 가정이 훨씬 잘 만족되도록 개선되었습니다.

잔차 등분산성 개선 (잔차 vs 예측값 산점도 비교)

- 원본 모형: 예측값이 커짐에 따라 잔차의 퍼진 정도(분산)가 일정하지 않고 나팔 모양이나 특정 패턴을 보이며 퍼져 나가는 등분산성 위반 양상이 나타납니다.
- 로그변환 모형 ($\log_1 p$): 예측값 전 구간에 걸쳐 잔차들이 0 을 중심으로 일정한 폭을 유지하며 무작위로(Randomly) 고르게 분포하므로, 등분산성 가정이 효과적으로 충족되어 회귀 모형의 신뢰성이 높아졌음을 확인할 수 있습니다.

Part 5. 타겟팅 (로지스틱 회귀)

13~14. 로지스틱 회귀 & 오즈비 해석

Q: 쿠폰 발송·멤버십 등급의 오즈비를 해석하고, 다음 캠페인 타겟 세그먼트를 정하세요.

쿠폰 발송 여부 오즈비 해석

campaign_group[T.treatment]의 오즈비는 약 $2.43(e^{0.8895})$ 으로, 쿠폰을 발송한 집단(treatment)이 미발송 집단(control)에 비해 캠페인에 반응(전환)할 오즈가 약 2.43배 증가합니다. 이는 쿠폰 발송이 고객 반응을 이끌어내는 데 매우 효과적임을 증명합니다.

멤버십 등급 오즈비 해석

Basic 등급을 기준으로 할 때, Gold 등급의 오즈비는 약 $2.02(e^{0.7024})$, Silver 등급은 약 $1.41(e^{0.3411})$ 로 나타났습니다. 즉, 멤버십 등급이 높을수록 캠페인 반응 오즈가 유의하게 증가하며, 특히 Gold 등급 고객은 Basic 고객에 비해 반응 오즈가 약 2배 높습니다.

다음 캠페인 타겟 세그먼트 제안

분석 결과를 종합할 때, 다음 마케팅 캠페인은 유입 채널 중 상대적으로 반응률이 높고 충성도가 높은 Influencer 채널 유입 고객이면서, 멤버십 등급이 높은 Gold 및 Silver 등급 고객층을 핵심 타겟으로 설정하여 집중 공략해야 합니다.

[DailyBox 마케팅 전략 제안 보고서]

1. 캠페인 지속 여부 (Part 3 & 5 근거)

- 결론: 다음 분기 쿠폰 캠페인 지속 진행
- 근거: 쿠폰 발송 집단(treatment)의 월 매출 평균이 미발송 집단(control)보다 통계적으로 유의하게 높고($p < 0.05$), 로지스틱 회귀 결과 쿠폰 발송 시 반응 오즈가 약 2.43배 증가하므로 예산 집행을 지속해야 합니다.

2. 채널 예산 배분 전략 (Part 1 & 3 근거)

- 결론: Influencer 채널 중심의 예산 집중 및 차별화
- 근거: One-way ANOVA 및 사후검정 결과 Influencer 채널이 가장 높은 구매력을 가진 고가치 고객을 데려오며, Two-way ANOVA에서 채널별 교호작용이 유의하므로 채널 특성에 맞춘 예산 재배분이 필요합니다.

3. 매출 레버 제안 (Part 4 근거)

- 결론: 방문 횟수 증대 및 효율적인 온라인 광고비 집행
- 근거: 다중회귀 분석 결과 monthly_visits와 online_ad_cost가 매출에 유의한 양(+)의 기여를 합니다. 단, 할인율(avg_discount_rate)의 경우 매출 외형을 키울 수 있으나 무분별한 확대는 마진을 악화시키므로 신중한 접근이 필요합니다. 다중공선성 문제가 확인된 합계 광고비(total_ad_cost)는 모형에서 배제해야 합니다.

4. 타겟팅 세그먼트 (Part 5 근거)

- 결론: Gold/Silver 상위 멤버십 및 Influencer 유입 고객 집중 타겟팅
- 근거: 로지스틱 회귀 오즈비 분석 결과, Gold 등급($OR \approx 2.02$)과 Silver 등급($OR \approx 1.41$) 고객이 캠페인 반응 확률이 훨씬 높으므로, 이들 고가치 세그먼트에 개인화된 쿠폰을 우선 발송해야 합니다.

5. 분석의 한계

- 데이터 스냅샷: 본 분석은 특정 시점의 1개월치 스냅샷 데이터를 기반으로 하므로 장기적인 고객 생애 가치(LTV)를 온전히 반영하기 어렵습니다.
- 인과 해석의 범위: 무작위 배정된 캠페인 그룹 외의 유입 채널이나 멤버십 등급은 관측 데이터이므로 교란 변수의 영향(내생성 문제)이 완전히 배제되지 않았음을 유의해야 합니다.