

신용카드 사기 탐지 과제 제출용 보고서 (Report)

응용통계학과 2024122026 윤소현

1. SMOTE 적용 이유 서술

: 신용카드 데이터셋은 정상 거래(Class 0)가 284,315건인 반면, 사기 거래(Class 1)는 492건에 불과한 극심한 클래스 불균형문제를 지니고 있습니다. 이 상태로 모델을 학습시키면 모델은 위험 부담을 피하기 위해 대부분의 거래를 정상(0)으로 예측하는 편향이 생겨 실제 사기 거래를 분류하지 못합니다. SMOTE를 학습 데이터(X_{train})에만 적용하여 소수 클래스인 사기 거래 데이터를 394건에서 7,999건으로 인위적으로 합성·증대시켰습니다. 이를 통해 모델이 정상 거래에 편향되지 않고 사기 거래의 고유한 패턴 특성을 집중적으로 습득할 수 있도록 유도했습니다.

2. 최종 모델 성능 평가 및 목표 달성 여부 (Step 6 ~ 7)

실험에서 도출된 수치를 바탕으로 목표 지표 달성 여부를 검증했습니다.

최종 지표 요약표 (Custom Threshold = 0.7 기준)

구분	Precision	Recall	F1-Score	Support
Class 0 (정상 거래)	0.9920	0.9970	0.9945	2001
Class 1 (사기 거래)	0.9318	0.8367	0.8817	98
PR-AUC Score	-	-	0.9089	-

목표 달성 여부 검증:

- Recall (Class 1) ≥ 0.80 : 0.8367 달성으로 목표를 충족했습니다.
- F1-score (Class 1) ≥ 0.88 : 0.8817 달성으로 목표를 충족했습니다.
- PR-AUC ≥ 0.90 : 0.9089 달성으로 목표를 충족했습니다.
- Class 0 (정상 거래) 지표: Precision 0.9920, Recall 0.9970, F1-score 0.9945로 Class 0과 Class 1 모두 높은 분류 성능을 보였습니다.

임계값(Threshold) 조정 효과 해석:

Default Threshold(0.5)일 때의 PR-AUC는 0.9089이며, Class 1의 Recall은 0.8469, Precision은 0.8646이었습니다.

Threshold를 0.7로 조정함으로써 Precision이 0.8646에서 0.9318로 대폭 상승하였고, F1-score 역시 0.8817을 기록하며 Target 기준인 $F1 \geq 0.88$ 과 $Recall \geq 0.80$ 을 동시에 완벽하게 만족시키는 최적의 오차 행렬을 도출할 수 있었습니다.

3. 추가 시도 및 성능 향상 제언

목표 지표를 성공적으로 달성하였으나, 추가적인 성능 향상을 위해 다음 기법들을 시도해 볼 수 있습니다.

1. 정교한 Threshold Tuning: 0.5부터 0.9까지 0.01 단위로 Precision-Recall 곡선을 그리며 F1-score가 극대화되는 정확한 optimal threshold 탐색하기
2. 복합 모델 앙상블 (Ensemble): XGBoost 외에도 LightGBM, CatBoost 모델을 추가 구축하여 Soft Voting 방식의 앙상블 적용하기
3. 하이퍼파라미터 최적화: Optuna 라이브러리를 활용하여 XGBoost의 max_depth, subsample, colsample_bytree 파라미터 최적화 진행하기